

장동은

BIRTH 1996.10.01
PHONE 010-6472-6803
EMAIL euncrest@gmail.com
ADDRESS 서울특별시 강남구 개포로 409



github.com/72yh/portfolio

EDUCATION

2025.08 성균관대학교 통계학과 석사 졸업
4.50 / 4.50
대학원 우수 장학금, 100% (2024.1학기 - 2025.1학기)

2024.02 성균관대학교 통계학과 학사 졸업
4.44 / 4.50
학·석사 연계 장학금, 100% (2023.2학기)
성적 우수 장학금, 10% (2022.2학기 - 2023.1학기)
수석 입학 국가 장학금, 10% (2022.1학기)

CERTIFICATES

2025.07 빅데이터분석기사
2025.04 SQL 개발자(SQLD)
2025.02 OPlc AL
2024.11 데이터 분석 준전문가(ADsP)


PROJECTS

2026.06 Paper Recommender: 언어 모형 기반 논문 추천 웹 서비스
2025.08 식음업장 메뉴 수요 예측 AI 온라인 해커톤
2025.08 2025 문화 디지털혁신 및 데이터 활용 공모전
2025.07 Boost up AI 2025: 신약 개발 경진대회
2025.06 갑상선암 진단 분류 해커톤: 양성과 악성, AI로 정확히 구분하라!
2025.06 2025 날씨 빅데이터 콘테스트
2025.05 건설용 자갈 암석 종류 분류 AI 경진대회

Paper Recommender: 언어 모델 기반 논문 추천 웹 서비스

arXiv URL을 입력하면 유사 논문을 추천하는 웹 서비스를 구현했습니다.



논문의 초록과 카테고리를 언어 모델 기반의 임베딩으로 변환한 뒤, 양자화를 적용해 저비용 배포가 가능한 벡터 데이터베이스를 구축했습니다. 사용자 입력 논문을 기준으로 ANN 기반의 코사인 유사도 검색을 수행해 유사한 논문을 반환하도록 구성했으며, 배포 과정에는 에이전트 기반의 개발 도구를 활용했습니다.



식음업장 메뉴 수요 예측 AI 온라인 해커톤

곤지암 리조트의 식음업장별·메뉴별 수요를 예측하는 모델을 구현했습니다.


과거 4주의 판매 데이터를 바탕으로 향후 1주의 수요를 예측하는 다중 시점·다변량 시계열 회귀 모델입니다. 목표 변수의 영과잉 특성을 고려해 Tweedie 분포를 가정한 부스팅 모델을 학습했으며, Poisson 분포를 가정한 랜덤 포레스트와 별도의 딥러닝 모델을 더해 앙상블을 구성했습니다. 또한 기존 Scikit-Learn의 TimeSeriesSplit이 다변량 시계열 데이터의 학습·검증 폴드를 올바르게 분할하지 못하는 문제를 해결하기 위해 BaseCrossValidator를 상속한 교차 검증 전용 분할기를 직접 구현했습니다.



2025 문화 디지털혁신 및 데이터 활용 공모전

리뷰 텍스트를 분석해 글로벌 대비 국내 성과가 두드러진 영화의 성공 요인을 도출했습니다.


프로젝트 합류 전 제출된 분석 제안서에 따라 AI 기반 점수, 감성 사전, 부스팅을 활용한 감성 분석을 수행했습니다. 해석 가능성을 우선해 감성 사전과 부스팅 중심으로 국내 특화 여부를 이진 분류하고, SHAP으로 주요 요인을 해석했습니다. 다만 두 기법만으로는 리뷰의 문맥을 충분히 반영하기 어려워, 문맥을 압축하면서도 직관적으로 해석 가능한 BERT 기반 긍정률을 AI 기반 점수로 입력했습니다.



Boost up AI 2025: 신약 개발 경진대회

분자 구조를 바탕으로 특정 약물 대사 효소(CYP3A4)의 저해율을 예측하는 모형을 구현했습니다.



약 1,600개 분자의 고유 문자열(SMILES)이 학습 데이터로 제공되었습니다. 약 170종, 2,000차원 이상의 특성이 해당 문자열로부터 추출되었고, PCA와 의사결정나무 기반 모형으로 고차원 문제에 대응했습니다. 이후 일반화 성능을 높이기 위해 1,000만 개 분자로 사전 학습된 GNN을 추가 도입하고, 가중 평균 방식으로 앙상블을 구성했습니다.



갑상선암 진단 분류 해커톤: 양성과 악성, AI로 정확히 구분하라!

의료 정형 데이터 기반의 갑상선암 진단 모형을 구현했습니다.


데이터 불균형을 고려해 StratifiedKFold로 교차검증을 수행했으며, 과표본화와 불순도 가중치를 적용한 부스팅과 랜덤 포레스트를 사용했습니다. 각 모형의 Softmax 출력값을 단순 평균한 뒤, 교차검증 F1 Score를 최대화하는 임계값을 도출해 앙상블을 구성했습니다.



2025 날씨 빅데이터 콘테스트

인력 배정을 위해 부산시 각 소방서의 신고 건수를 예측하는 시공간 회귀 모형을 구현했습니다.

기상·소방 데이터의 INNER JOIN 결과가 제공되었습니다. 실제 신고 건수가 0인 날은 배제되었고, 이에 영과잉을 고려하지 않는 부스팅과 랜덤 포레스트로 접근했습니다. 군·구 및 읍면동의 공간적 특성을 반영하기 위해 기상 요인 외의 변수를 수집했고, Scikit-Learn의 TargetEncoder가 시계열 데이터의 유출을 완벽하게 차단하기 어렵다는 점을 고려해 이를 방지하는 TargetEncoder 파이프라인을 직접 설계했습니다.



건설용 자갈 암석 종류 분류 AI 경진대회

콘크리트 품질 유지를 위해 건설용 암석 이미지를 일곱 종류로 구분하는 분류기를 구현했습니다.

가장 많은 클래스의 데이터가 가장 적은 클래스보다 5배 많아, 데이터 불균형을 완화하기 위해 과표본화와 손실 함수 가중치를 적용했습니다. 또한 제한된 컴퓨팅 환경에서도 학습과 추론이 가능하도록 서로 다른 유형의 경량 모델을 다수 앙상블하고, 자동 혼합 정밀도를 적용했습니다.

